

Инструкция по подключению локального анализа телефонных разговоров

Файл `voice_description.py` распознаёт русскую речь, определяет смену говорящих и создаёт Excel-таблицу с таймкодами. Все вычисления выполняются на локальном компьютере.

Основная точка входа: `analyze_call(filename: str) -> pathlib.Path`
Передайте путь к аудиозаписи. Функция вернёт путь к созданному Excel-файлу.

1. Что передавать пользователю

Минимальный комплект должен сохранять следующую структуру:

```
project/
|-- voice_description.py
|-- voice_settings.json
|-- start_example.py
|-- requirements.txt
|-- download_models.py
`-- models/
    |-- faster-whisper-small/
    |-- sherpa-onnx-pyannote-segmentation-3-0/
    `-- 3dspeaker_speech_eres2net_base_sv_zh-cn_3dspeaker_16k.onnx
```

- `voice_settings.json` хранит все пользовательские параметры анализа.
- Если `voice_settings.json` отсутствует, первый вызов `analyze_call` создаст его рядом со скриптом и заполнит значениями по умолчанию. Папка должна быть доступна для записи.
- Папка `models` должна находиться рядом с `voice_description.py`.
- Если модели переданы вместе с проектом, интернет для анализа не нужен.

2. Требования

- 64-битный Python 3.9 или новее. Проверенная конфигурация: Python 3.12.13.
- Работа на CPU, видеокарта NVIDIA не обязательна.
- Около 550 МБ свободного места для весов моделей, плюс место для окружения.
- Поддерживаются WAV, MP3, M4A, MP4, MPEG, MPGA, OGG, FLAC и WEBM.

3. Ограничения аудиофайла

Жёсткого лимита в мегабайтах нет. При значении `limits.max_file_size_mb = 0` код принимает любой размер, который помещается на диске и декодируется PyAV. Ограничения облачного API отсутствуют.

- Размер сжатого MP3/M4A не показывает реальный расход памяти. После декодирования звук хранится как моно 16 кГц float32.
- Сырой аудиомассив занимает около 230 МБ на один час записи. Дополнительно память используют Whisper, ONNX-диаризация и промежуточные данные.
- Текущая реализация держит декодированную запись целиком в RAM. Время работы растёт примерно вместе с длительностью записи.
- Стерео и многоканальный звук сводится в моно. Защищённые DRM-файлы и повреждённые контейнеры не поддерживаются.
- Для компьютера с 8 ГБ RAM разумно начинать с записей до 60-120 минут и проверять фактическое потребление памяти.

Защитные ограничения

В `voice settings.json` можно задать `max_file_size_mb` и `max_duration_minutes`. Значение 0 отключает соответствующий лимит. Лимит длительности проверяется во время декодирования и останавливает обработку до накопления чрезмерного массива.

```
"limits": {  
  "max_file_size_mb": 500,  
  "max_duration_minutes": 120  
}
```

4. Установка библиотек

Рекомендуется устанавливать зависимости в отдельное виртуальное окружение.

```
cd "C:\path\to\project"  
python -m venv .venv  
.\venv\Scripts\python.exe -m pip install -r requirements.txt
```

Без requirements.txt:

```
python -m pip install "faster-whisper>=1.2,<2" ^  
  "sherpa-onnx>=1.10.28,<2" "openpyxl>=3.1,<4"
```

5. Установка локальных моделей

Если папка `models` уже передана пользователю, этот шаг пропускается. Иначе один раз выполните команду при наличии интернета:

```
.\.venv\Scripts\python.exe download_models.py
```

`download_models.py` использует HTTPS только для первоначального скачивания весов. Функция `analyze_call` не содержит сетевых запросов и после установки работает офлайн.

6. Основная функция

```
def analyze_call(filename: str) -> pathlib.Path
```

Параметр	Описание
filename	Строка с абсолютным или относительным путём к аудиофайлу.
Относительный путь	Сначала ищется от рабочей папки, затем от папки <code>voice description.py</code> .
Результат	<code>pathlib.Path</code> с абсолютным путём к созданному Excel-файлу.
Имя результата	<имя аудио> transcript.xlsx в папке исходной записи.

Пример прямого вызова

Из-за пробела в имени `voice description.py` используется `importlib`. Готовая реализация находится в `start example.py`.

```
import importlib.util, sys
from pathlib import Path

script = Path(__file__).with_name("voice description.py")
spec = importlib.util.spec_from_file_location("voice_description", script)
module = importlib.util.module_from_spec(spec)
sys.modules[spec.name] = module
spec.loader.exec_module(module)
excel_path = module.analyze_call(r"C:\records\call.wav")
```

Запуск готового примера

```
.\.venv\Scripts\python.exe "start example.py"
```

При каждом вызове `analyze_call` настройки заново читаются из `voice settings.json`. Если файл удалён или ещё не передан, код автоматически создаёт его с полными значениями по умолчанию. JSON не поддерживает комментарии и завершающие запятые. Неизвестное или неверное поле вызывает понятную ошибку.

7. Настройки распознавания

Раздел recognition в voice settings.json управляет faster-whisper.

Параметр	По умолчанию	Как влияет
language	"ru"	Язык записи. Для короткой русской записи явное "ru" надёжнее. null включает автоопределение.
device	"cpu"	cpu, cuda или auto. cuda требует совместимую NVIDIA-среду.
compute_type	"int8"	int8 экономит CPU/RAM. Для CUDA обычно используют float16 или int8_float16.
cpu_threads	0	0 выбирает автоматически до 8 потоков. Больше потоков может ускорить обработку, но не улучшает текст.
beam_size	5	Ширина поиска. На example значение 10 добавило ошибочные фразы, поэтому по умолчанию оставлено 5. Диапазон 1-20.
temperature	0.0	0.0 даёт стабильный дословный результат. Повышение увеличивает вариативность и риск выдуманного текста.
condition_on_previous_text	true	Сохраняет контекст между фрагментами. false помогает при циклических повторах и переносе ошибки дальше.
vad_filter	true	Убирает участки без речи до распознавания. Обычно следует оставить true.
vad_min_silence_duration_ms	200	Минимальная пауза для VAD. Значение 200 мс чувствительнее к коротким телефонным репликам.
initial_prompt	""	Контекст: тематика, имена, адреса, бренды и стиль записи. Один из главных способов улучшить термины.
hotwords	""	Ключевые слова и имена, которым нужно дать больший вес при распознавании.

Для имён и адресов заполните оба поля, например: initial_prompt = "Звонок в службу такси. Адреса в Санкт-Петербурге." и hotwords = "Пулково Просвещения Невский". Подсказка должна содержать только вероятные термины.

8. Настройки разделения голосов

Раздел diarization управляет sherpa-onnx.

Параметр	По умолчанию	Как влияет
num_speakers	-1	-1 определяет число автоматически. На коротком mono-example принудительные 2 собеседника схлопнули интервалы в один голос.
cluster_threshold	0.55	Используется при num_speakers = -1. Больше значение даёт меньше голосов, меньшее - больше. Меняйте шагом 0.03-0.05.
window_shift_ratio	0.1	Меньшее значение повышает временную детализацию, но замедляет диаризацию. На example значение 0.05 не улучшило результат.
min_duration_on	0.3	Минимальный речевой фрагмент. Уменьшайте для коротких Да/Нет; увеличивайте, если шум определяется как речь.
min_duration_off	0.5	Заполняет короткие разрывы внутри речи. Большее значение сильнее склеивает паузы.

Настройка объединения реплик

Параметр	По умолчанию	Как влияет
postprocessing.merge_max_gap_seconds	0.45	Максимальная пауза, при которой слова одного голоса объединяются в строку Excel. Небольшое значение не даёт склеивать короткие реплики.

Настройки ограничений

Параметр	По умолчанию	Как влияет
limits.max_file_size_mb	0	Максимальный размер исходного файла в МиБ. 0 отключает проверку.
limits.max_duration_minutes	0	Максимальная длительность записи в минутах. 0 отключает проверку.

Совместимость с переменной окружения

VOICE_NUM_SPEAKERS по-прежнему поддерживается и имеет приоритет над diarization.num_speakers. Для постоянной настройки предпочтительнее JSON.

```
$env:VOICE_NUM_SPEAKERS = "2"
.\.venv\Scripts\python.exe "start example.py"
```

9. Готовые рекомендации по точности

Обычный звонок, два собеседника

- Для короткой моно-записи сначала оставьте `diarization.num_speakers = -1`. Точное значение проверяйте сравнением на всём разговоре.
- Оставьте `language = "ru"`, `temperature = 0.0` и `vad_filter = true`.
- При шуме можно проверить `beam_size = 7`, но увеличение иногда добавляет выдуманный текст. На example значение 5 оказалось лучше 10.
- Код использует нормализованное перекрытие голосовых интервалов: короткий уверенный ответ имеет приоритет над длинным пересекающимся интервалом.

Имена, адреса и профессиональные термины

- Добавьте короткое описание разговора в `initial_prompt`.
- Перечислите вероятные имена, города, модели и аббревиатуры в `hotwords`.
- Не добавляйте маловероятные слова: подсказка может смещать распознавание.

Определяется слишком много голосов

- Лучший вариант - задать точное `num_speakers`.
- При автоматическом режиме немного увеличьте `cluster_threshold`, например 0.55 -> 0.60.

Разные голоса ошибочно объединяются

- При автоматическом режиме уменьшите `cluster_threshold`, например 0.55 -> 0.50.
- Уменьшайте/увеличивайте порог постепенно и проверяйте весь диалог.

Повторяющийся или выдуманный текст

- Оставьте `temperature = 0.0` и попробуйте `condition_on_previous_text = false`.
- Проверьте, что `initial_prompt` и `hotwords` не содержат неверных предположений.

10. Что создаётся в Excel

Колонка	Пример	Содержание
Таймлайн	00:06.000-00:10.980	Начало и окончание реплики.
Собеседник	Собеседник А	Автоматически назначенная метка голоса.
Что сказано	Текст реплики	Результат локального распознавания.

11. Типовые ошибки

- Локальные модели не установлены: запустите `download_models.py` или передайте папку `models`.
- Не установлена библиотека: запускайте проект тем же Python, в который выполнен `pip install`.
- Ошибка JSON: удалите комментарии и завершающие запятые, проверьте имена полей.
- Ошибки в именах и адресах: используйте `initial_prompt/hotwords` и проверяйте Excel перед автоматической обработкой.

Справочные проекты

faster-whisper: <https://github.com/SYSTRAN/faster-whisper>

sherpa-onnx: <https://github.com/k2-fsa/sherpa-onnx>